项目概要介绍

【A23】【DocFusion】基于大语言模型的文档理解与多源数据融合系统　项目概要介绍

编 写 人：　Blossoms pave your way 团队

使 用 人：　Blossoms pave your way 团队

密　　级：　内部文档

日　　期：　2026-04-20

一、前言

党政与企事业单位沉淀大量公文、统计公报、合同等非结构化材料，**格式多样、信息分散、重复填报** 痛点突出。**DocFusion** 依托 **LLM+RAG**，融合 **混合抽取、智能填表、Agent 工具调用**，构建"**接入—抽取—成稿—核验—看板**"闭环。

二、创意描述

（一）技术定位与核心目标

1）文档智能闭环：覆盖 **pdf/docx/xlsx/doc/图片**主流格式，**同平台完成上传到成稿。**

2）混合抽取 多源融合："**规则+LLM JSON + 融合**"三段式，支持**别名归一、加权投票、置信度。**

3）对话即操作：tool_use/tool_result 驱动多轮 Agent，一句话完成**抽取→编辑→排版→制图→填表。**

4）开放双通道：OpenAPI（n8n/Coze/Dify）+**MCP**（Claude Desktop/Cursor）。



图 2-1 DocFusion 工作台

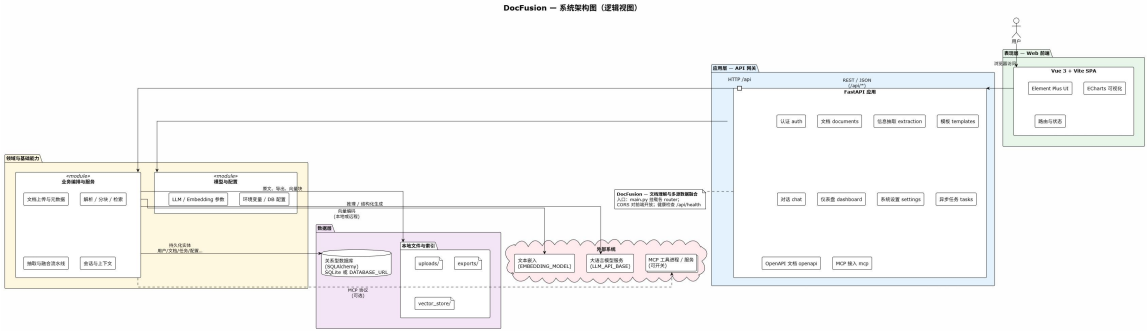
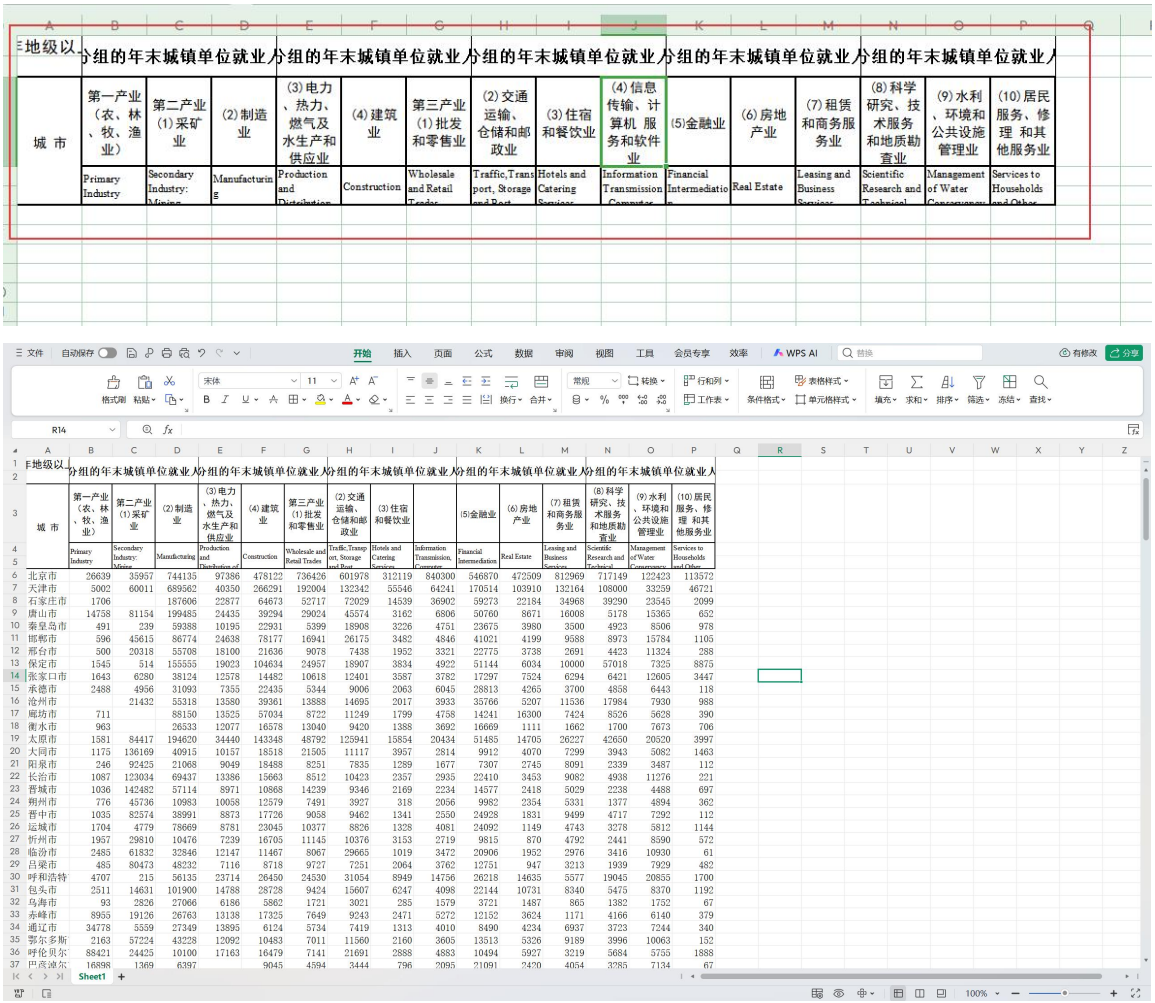


图 2-2 DocFusion 系统架构图

（二）创新点与解决思路

1）**混合抽取管道：**正则+**LLM 强制 JSON** 并行，fusion 归一投票，**召回、准确、稳定兼顾。**

2）**smart_fill 智能填表：保留合并单元格与表头样式，**模糊匹配列名，**合计/平均自动汇总。**



城市	第一产业（农、林、牧、渔业）	第二产业（1）采矿业	（2）制造业	（3）电力、热力、燃气及水生产和供应业	（4）建筑业	第三产业（1）批发和零售业	（2）交通运输、仓储和邮政业	（3）住宿和餐饮业	（4）信息传输、计算机服务和软件业	（5）金融业	（6）房地产业	（7）租赁和商务服务业	（8）科学研究、技术服务和地质勘查业	（9）水利、环境和公共设施管理业	（10）居民服务、修理和其他服务业
	Primary Industry	Secondary Industry: Mining	Manufacturing	Production and Distribution of	Construction	Wholesale and Retail Trades	Traffic, Transport, Storage and Post	Hotels and Catering Services	Information Transmission, Computer	Financial Intermediation	Real Estate	Leasing and Business Services	Scientific Research and Technical	Management of Water Conservancy	Services to Households and Other
北京市	26639	35957	744135	97386	478122	736426	601978	312119	840300	546870	472509	812969	717149	122423	113572
天津市	5002	60011	689562	40350	266291	192004	132342	55546	64241	170514	103910	132164	108000	33259	46721
石家庄市	1706		187606	22877	64673	52717	72029	14539	36902	59273	22184	34968	39290	23545	2099
唐山市	14758	81154	199485	24435	39294	29024	45574	3162	6806	50760	8671	16008	5178	15365	652
秦皇岛市	491	239	59388	10195	22931	5399	18908	3226	4751	23675	3980	3500	4923	8506	978
邯郸市	596	45615	86774	24638	78177	16941	26175	3482	4846	41021	4199	9588	8973	15784	1105
邢台市	500	20318	55708	18100	21636	9078	7438	1952	3321	22775	3738	2691	4423	11324	288
保定市	1545	514	155555	19023	104634	24957	18907	3834	4922	51144	6034	10000	57018	7325	8875
张家口市	1643	6280	38124	12578	14482	10618	12401	3587	3782	17297	7524	6294	6421	12605	3447
承德市	2488	4956	31093	7355	22435	5344	9006	2063	6045	28813	4265	3700	4838	6443	118
沧州市		21432	55318	13580	39361	13888	14695	2017	3933	35766	5207	11536	17984	7930	988
廊坊市	711		88150	13525	57034	8722	11249	1799	4758	14241	16300	7424	8526	5628	390
衡水市	963		26533	12077	16578	13040	9420	1388	3692	16669	1111	1662	1700	7673	706
太原市	1581	84417	194620	34440	143348	48792	125941	15854	20434	51485	14705	26227	42650	20520	3997
大同市	1175	136169	40915	10157	18518	21505	11117	3957	2814	9912	4070	7299	3943	5082	1463
阳泉市	246	92425	21068	9049	18488	8251	7835	1289	1677	7307	2745	8091	2339	3487	112
长治市	1087	123034	69437	13386	15663	8512	10423	2357	2935	22410	3453	9082	4938	11276	221
晋城市	1036	142482	57114	8971	10868	14239	9346	2169	2234	14577	2418	5029	2238	4488	697
朔州市	776	45736	16983	10058	12579	7491	3927	318	2056	9982	2354	5331	1377	4894	362
晋中市	1035	82574	38991	8873	17726	9058	9462	1341	2556	24928	1831	9499	4717	7292	112
运城市	1704	4779	78669	8781	23045	10377	8826	1328	4081	24092	1149	4743	3278	5812	1144
忻州市	1957	29810	10476	7239	16705	11145	10376	3153	2719	9815	870	4792	2441	8590	572
临汾市	2485	61832	32846	12147	11467	8067	29665	1019	3472	20906	1952	2976	3416	10930	61
吕梁市	485	80473	48232	7116	8718	9727	7251	2064	3762	12751	947	3213	1939	7929	482
呼和浩特	4707	215	56135	23714	26450	24330	31054	8949	14756	26218	14635	5577	19045	20855	1700
包头市	2511	14631	101900	14788	28728	9424	15607	6247	4098	22144	10731	8340	5475	8370	1192
乌海市	93	2826	27066	6186	5862	1721	3021	285	1579	3721	1487	865	1382	1752	67
赤峰市	8955	19126	26763	13138	17325	7649	9243	2471	5272	12152	3624	1171	4166	6140	379
通辽市	34778	5559	27349	13895	6124	5734	7419	1313	4010	8490	4234	6937	3723	7244	340
鄂尔多斯	2163	57224	43228	12092	10483	7011	11560	2160	3605	13513	5326	9189	3996	10063	152
呼伦贝尔	88421	24425	10100	17163	16479	7141	21691	2888	4883	10494	5927	3219	5684	5755	1888
巴彦淖尔	16898	1369	6397		9045	4594	3444	796	2095	21091	2420	4054	3285	7134	67

图 2-3 smart_fill 模板智能填表结果示意

3）**多模态图片填充：**兼容 **WPS DISPIMG** 与浮动图片；对话支持 **base64** 多模态。

4）**Agent 多轮调用：12 轮循环驱动 12 项工具，**自然语言完成 Word/Excel 编辑、制图、填表。

```python
# ---- Agent 循环 (tool-use) ----
tool_actions = []
final_answer = ""

try:
    for _round in range(MAX_TOOL_ROUNDS):
        resp = await call_llm(
            messages, system=system, temperature=0.3,
            max_tokens=3000, tools=AGENT_TOOLS,
        )

        text_part = resp.get("text", "")
        tool_calls = resp.get("tool_calls", [])
        stop_reason = resp.get("stop_reason", "")

        if not tool_calls or stop_reason != "tool_use":
            final_answer = text_part
            break

        assistant_content = []
        if text_part:
            assistant_content.append({"type": "text", "text": text_part})
        for tc in tool_calls:
            assistant_content.append({
                "type": "tool_use", "id": tc["id"],
                "name": tc["name"], "input": tc["input"],
            })
        messages.append({"role": "assistant", "content": assistant_content})

        tool_results_content = []
        for tc in tool_calls:
            t_name = tc["name"]
            t_input = tc["input"]
            logger.info(f"Agent 执行工具: {t_name}({json.dumps(t_input, ensure_ascii=False)[:200]})")
            try:
                result_str = await execute_tool(t_name, t_input, user.id)
            except Exception as te:
                logger.error(f"工具执行异常 {t_name}: {te}", exc_info=True)
                result_str = json.dumps({"error": str(te)[:200]})

            tool_actions.append({
                "tool": t_name, "input": t_input,
                "result": result_str[:500],
            })
```

图 2-4 Agent 多轮工具调用循环代码示意（chat.py 节选）

5）**兼容与降级：LibreOffice headless** 转.doc→.docx；检索缺模型时降级 **jieba + 词重叠**。

三、功能简介

（一）核心功能模块

1）**文档管理：**多格式上传、批量删除与重解析；支持 **批量 extract-all**。

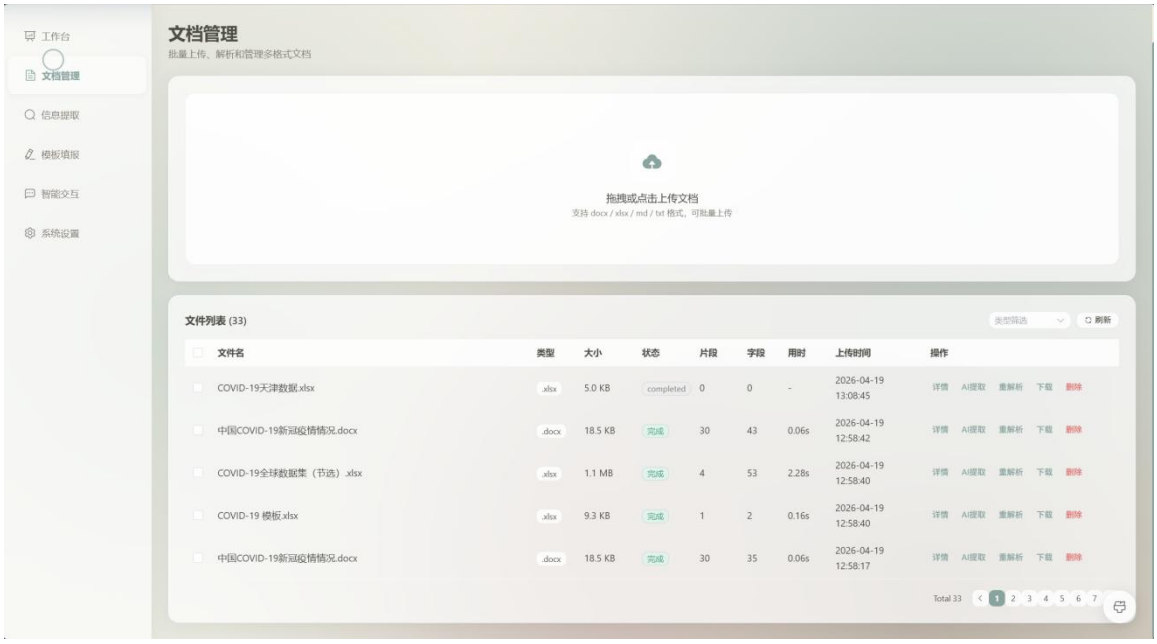


图 3-1 文档管理界面

2）信息抽取：字段浏览与就地编辑；**多源融合视图** 汇总多文档候选与置信度。

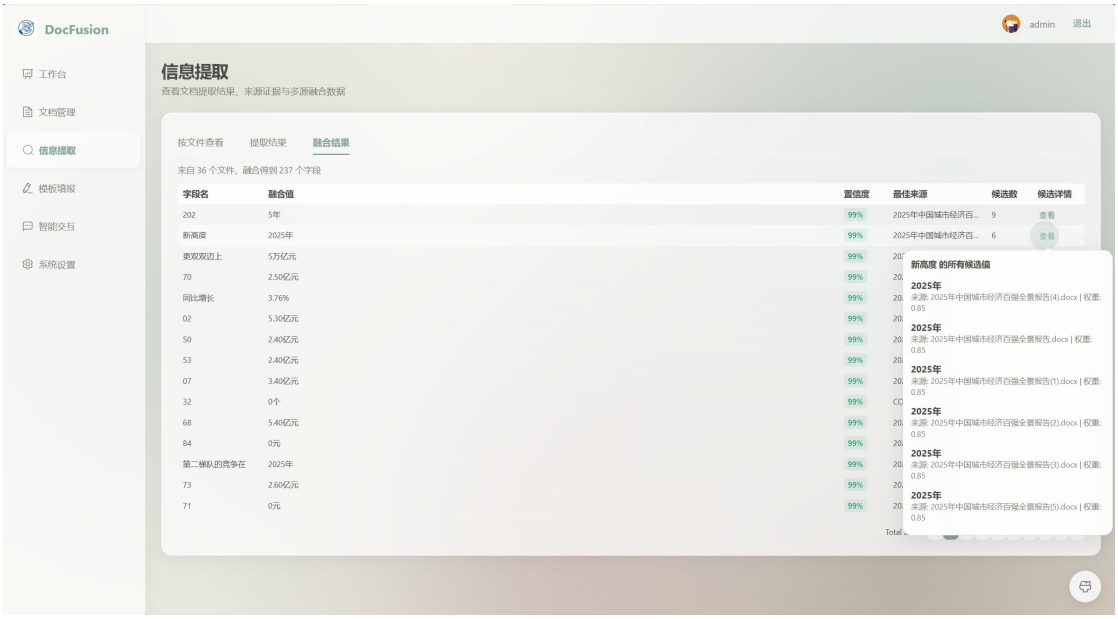


图 3-2 信息抽取与多源融合视图界面

3）智能填表：三类模板**字段自动识别**；可录入"**用户要求**"作筛选指令。

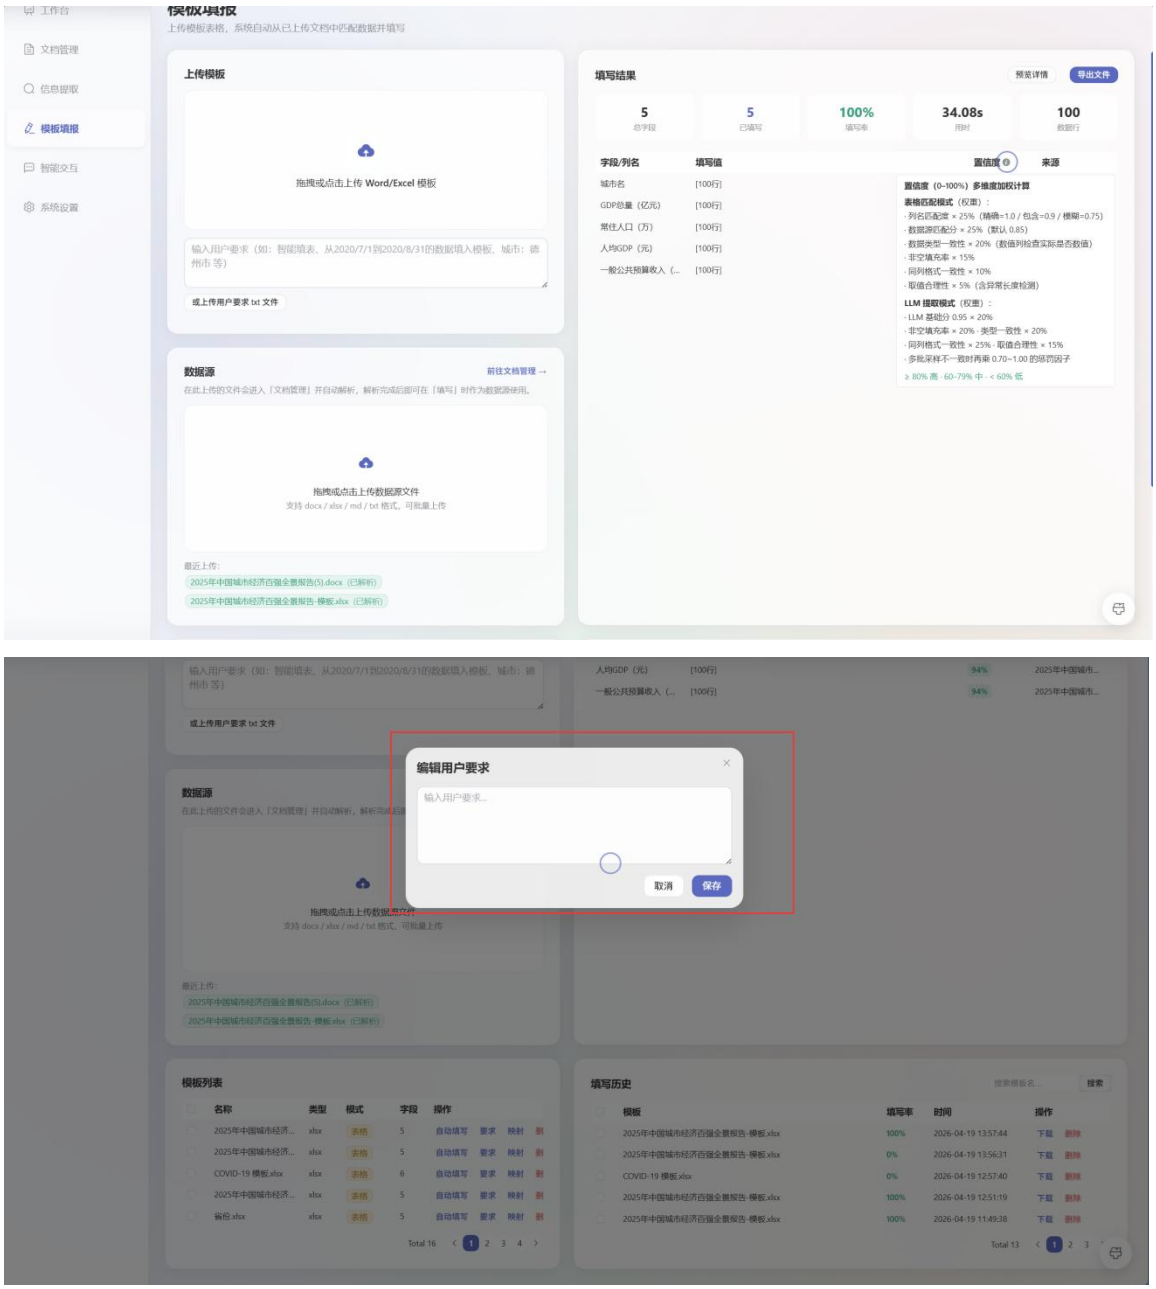
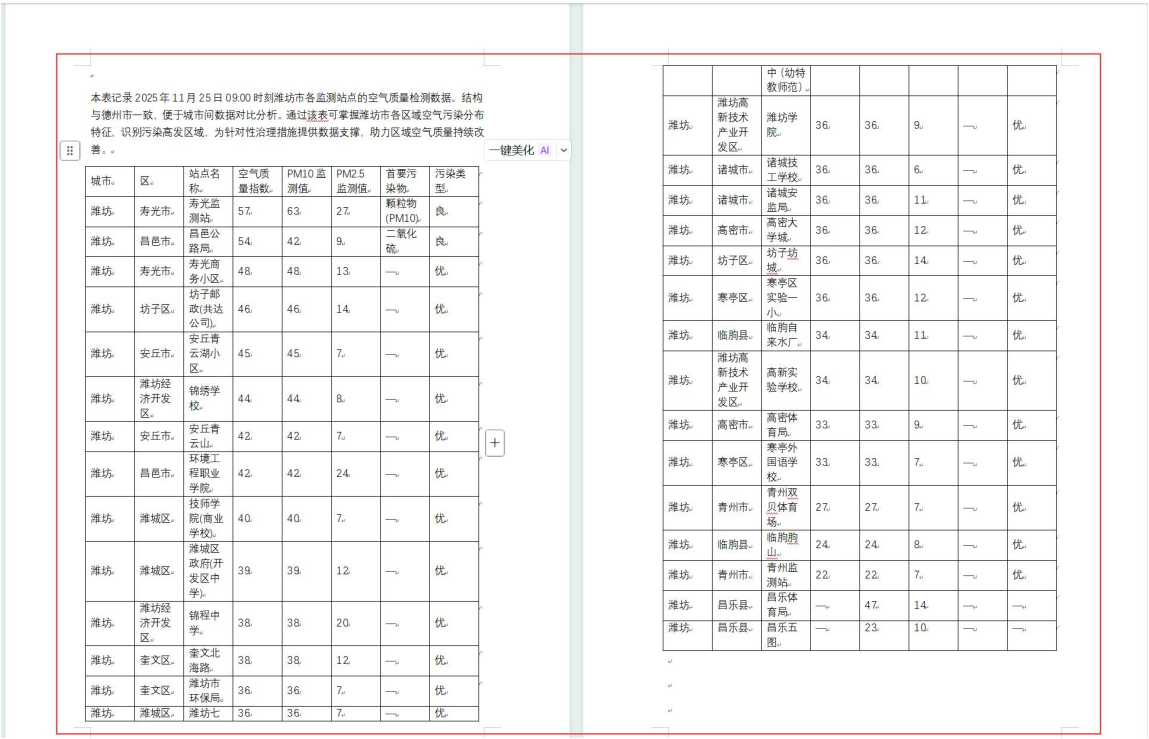


图 3-3 模板填表界面与“用户要求”输入



本表记录 2025 年 11 月 25 日 09:00 时刻潍坊市各监测站点的空气质量检测数据。结构与德州市一致，便于城市间数据对比分析。通过该表可掌握潍坊市各区域空气污染分布特征，识别污染高发区域，为针对性治理措施提供数据支撑，助力区域空气质量持续改善。

一键美化 AI

城市	区	站点名称	空气质量指数	PM10 监测值	PM2.5 监测值	首要污染物	污染类型
潍坊	寿光市	寿光监测站	57	63	27	颗粒物(PM10)	良
潍坊	昌邑市	昌邑公路局	54	42	9	二氧化硫	良
潍坊	寿光市	寿光商务小区	48	48	13	—	优
潍坊	坊子区	坊子邮政(共达公司)	46	46	14	—	优
潍坊	安丘市	安丘青云湖小区	45	45	7	—	优
潍坊	潍坊经济开发区	锦绣学校	44	44	8	—	优
潍坊	安丘市	安丘青云山	42	42	7	—	优
潍坊	昌邑市	环境工程职业学院	42	42	24	—	优
潍坊	潍城区	技师学院(商业学校)	40	40	7	—	优
潍坊	潍城区	潍城区政府(开发区中学)	39	39	12	—	优
潍坊	潍坊经济开发区	锦程中学	38	38	20	—	优
潍坊	奎文区	奎文北海路	38	38	12	—	优
潍坊	奎文区	潍坊市环保局	36	36	7	—	优
潍坊	潍城区	潍坊七	36	36	7	—	优

		中（幼特教师范）					
潍坊	潍坊高新技术产业开发区	潍坊学院	36	36	9	—	优
潍坊	诸城市	诸城技工学校	36	36	6	—	优
潍坊	诸城市	诸城安监局	36	36	11	—	优
潍坊	高密市	高密大学城	36	36	12	—	优
潍坊	坊子区	坊子坊城	36	36	14	—	优
潍坊	寒亭区	寒亭区实验一小	36	36	12	—	优
潍坊	临朐县	临朐自来水厂	34	34	11	—	优
潍坊	潍坊高新技术产业开发区	高新实验学校	34	34	10	—	优
潍坊	高密市	高密体育局	33	33	9	—	优
潍坊	寒亭区	寒亭外国语学校	33	33	7	—	优
潍坊	青州市	青州双贝体育场	27	27	7	—	优
潍坊	临朐县	临朐胡山	24	24	8	—	优
潍坊	青州市	青州监测站	22	22	7	—	优
潍坊	昌乐县	昌乐体育局	—	47	14	—	—
潍坊	昌乐县	昌乐五图	—	23	10	—	—

图 3-4 模板智能填表结果示意（山东空气质量测试集节选）

4）对话与 Agent：多会话、附件上传、**多文件上下文**，12 项工具联动。



图 3-5 智能对话界面与会话内多文件勾选

5）用户与权限：**JWT + bcrypt**，用户、角色与 **操作日志审计**。

6）系统设置与仪表盘：热配 **LLM API、Embedding、MCP**；**ECharts** 展示指标。

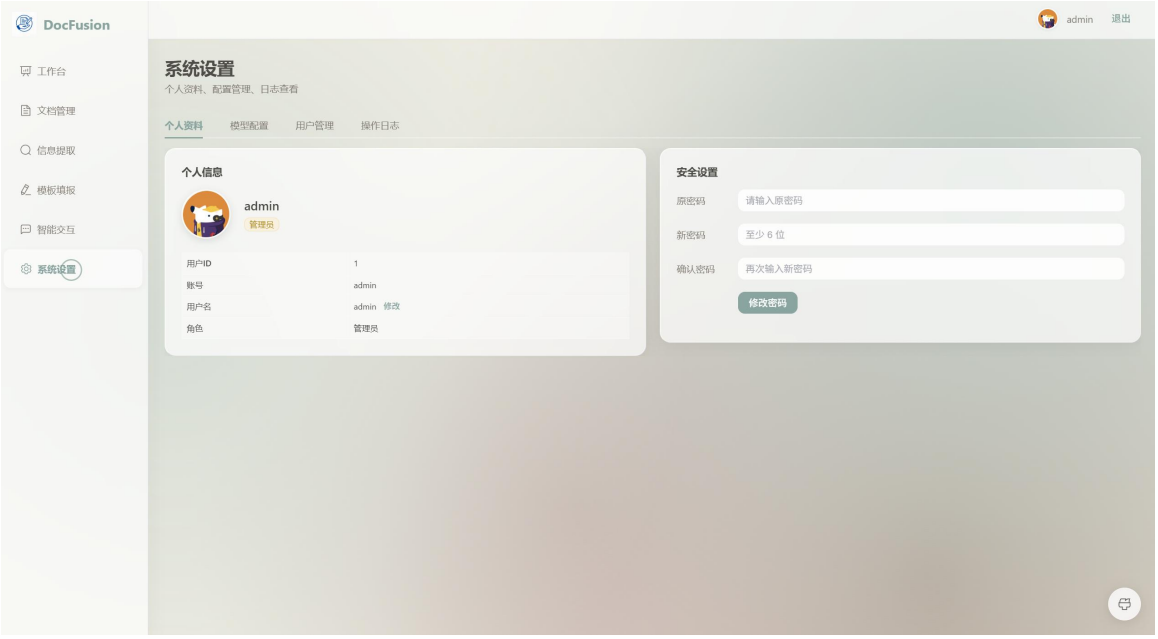


图 3-6 系统设置界面

（二）特色功能

1）本地化与安全：SQLite+本地存储，按 user_id 隔离。

2）开放接口：9 个 X-API-Key 端点，可被低代码平台编排。

3）MCP 外置：JSON-RPC + SSE 双通道，protocolVersion 2024-11-05。

4）主题个性化：8 套主题 + 自定义编辑器，玻璃拟态、Canvas 粒子页，CSS 热换肤。



图 3-7 个性化中心-主题预设与自定义编辑器

5）响应式：<768px 抽屉式导航，触控设备自动隐藏鼠标。

（三）特色综述

1）可控融合：三段式抽取 显著降低幻觉，可解释可追溯。

2）对话即操作：12 轮 Agent 将语言翻译为 Word/Excel 真实操作。

3）填表稳健：保留版式 **一次成稿**，兼容 WPS DISPIMG。

4）生态友好：**OpenAPI+MCP 双通道**，拥抱低代码与智能体。

5）体验闭环：响应式、玻璃拟态、动态主题，**兼顾效率与体验**。

四、开发工具与技术

类别	工具/技术栈	说明
后端框架	Python3+FastAPI+Uvicorn	异步 RESTful，11 个模块化路由。
前端框架	Vue3+VueRouter+Vite	组合式 API+SPA，Element Plus+ECharts。
数据访问	SQLAlchemy ORM	统一会话事务，可替换 PostgreSQL/MySQL。
认证机制	JWT (HS256)+bcrypt	axios 拦截器自动注入令牌。
大模型	Anthropic/OpenAI 双格式兼容	Base URL/Key/Model 热切换。
Agent 协议	Anthropic tool_use/tool_result	**12 轮循环驱动 12 项工具**。
RAG 与向量检索	Sentence transformers +NumPy 余弦相似度	按 user_id 隔离；缺模型时降级。
文档智能引擎	python-docx+openpyxl 自研 doc_editor	封装 Word 段落与 Excel 单元格/图表/校验。
抽取管道	hybrid_extract+fusion	正则+LLM JSON+归一+投票，输出置信度。
模板填表	smart_fill+template_filler+image_filler	保留版式、自动汇总、兼容 DISPIMG。
旧版兼容	LibreOffice headless/pywin32 COM	.doc → .docx；Windows

		可降级 COM。
文件处理	PyPDFLoader/docx/openpyxl/xlrd/图像库	解析 pdf/docx/xlsx/xls/图片。
开放生态	OpenAPI(/api/open)+MCP (/api/mcp)	**9 端点+JSON-RPC+SSE。**
前端体验	CSS 变量主题引擎+Canvas 2D+玻璃拟态	主题与偏好 localStorage 持久化。
DevOps 与部署	requirements.txt+npm+Nginx	前后端分离；.env 注入；支持容器编排。

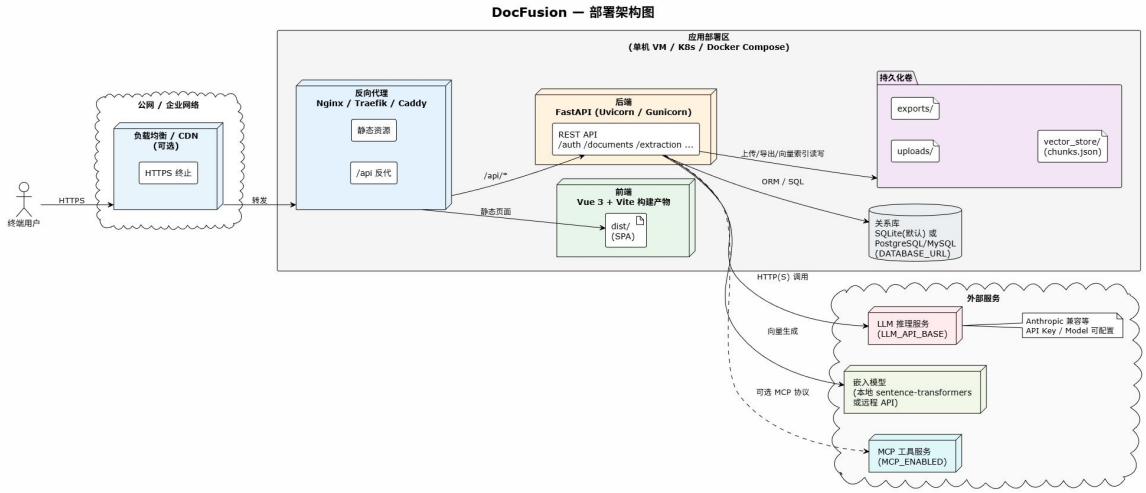


图 4-1 部署架构示意

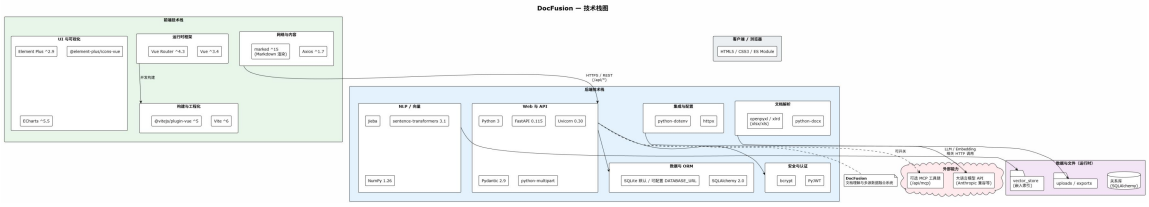


图 4-2DocFusion 系统技术栈示意

五、应用对象

1）党政与事业单位：公文、统计公报、模板成稿，**内网部署、数据不出域。**

2）企业中后台：合同/标书批量抽取，**与 OA、知识库无缝集成。**

3）低代码与 AI 团队：OpenAPI 接 n8n/Coze/Dify，MCP 接 Claude/Cursor。

4）科研与教育：学术报告与标准文档结构化提取与摘要。

六、应用环境

（一）硬件要求

1）**CPU**：4 核及以上。

2）**内存**：**≥16 GB**（本地嵌入建议 32 GB）。

3）**GPU**：可选；本地 LLM 建议**显存≥16 GB**。

4）**存储**：**≥100 GB SSD**。

（二）软件依赖

1）**系统**：Windows 10+/Ubuntu 20.04+/macOS 12+。

2）**运行环境**：**Python 3.10+、Node.js 18+**。

3）**后端**：FastAPI、SQLAlchemy、python-docx、openpyxl、jieba、sentence-transformers。

4）**前端**：Vue 3、Vite、Element Plus、ECharts。

5）**数据库**：**SQLite**，可切 PostgreSQL/MySQL。

6）**文档转换**：**LibreOffice 7.x** 或 Windows **pywin32 COM**。

7）**大模型**：兼容 **Anthropic / OpenAI**，热切换。

七、结语

DocFusion 以 **混合抽取、smart_fill、12 轮 Agent、OpenAPI/MCP 双通道** 串联文档闭环，形成 **可控、可融合、可成稿、可运营** 的文档智能底座。